


模式分类：杜达著

$$net_j = \sum_{i=1}^d \omega_{ji} x_i + \omega_{j0} = \omega_j^t x$$

$$net_k = \sum_{j=1}^{n_H} \omega_{kj} y_j + \omega_{k0} = \omega_k^t y$$

$$x = (x_0, x_1, \dots, x_d)^t, x_0 = 1 \quad \omega_j = (\omega_{j0}, \omega_{j1}, \dots, \omega_{jd})^t$$



$$x = (x_1, \dots, x_d)^T$$
$$t = (t_1, \dots, t_c)^T$$
$$J = \frac{1}{2} \sum_{k=1}^c (t_k - z_k)^2$$
$$f(net) = \frac{1}{1 + e^{-net}}$$
$$y_j = f(net_j)$$
$$z_k = f(net_k)$$
$$net_j = \sum_{i=1}^d \omega_{ji} x_i + \omega_{j0}$$
$$net_k = \sum_{j=1}^{n_H} \omega_{kj} y_j + \omega_{k0}$$

训练样本:  $(x, t)$

输入层：单元i的输入： $x_i$  单元数量： $d$

单元i的输出： $x_i$

单元i的激活函数：线性函数

隐层：单元j的输入： $net_j$  单元数量： $n_H$

$$net_j = \sum_{i=1}^d \omega_{ji} x_i + \omega_{j0} = \omega_j^t x$$

$$x = (x_0, x_1, \dots, x_d)^t, x_0 = 1$$

$$\omega_j = (\omega_{j0}, \omega_{j1}, \dots, \omega_{jd})^t$$

单元j的输出： $y_j = f(net_j)$

单元j的激活函数：非线性函数

输出层：单元k的输入： $net_k$  单元数量：c

$$net_k = \sum_{j=1}^{n_H} \omega_{kj} y_j + \omega_{k0} = \omega_k^t y$$

$$y = (y_0, y_1, \dots, y_{n_H})^t, y_0 = 1$$

$$\omega_k = (\omega_{k0}, \omega_{k1}, \dots, \omega_{kn_H})^t$$

单元k的输出： $z_k = f(net_k)$

单元k的激活函数：非线性函数

## 两层神经网络分类器

$$f(net) = \frac{1}{1 + e^{-net}}$$

(1) 分类问题: **C**类分类

(2) 特征空间维数: **d**

(3) 已知条件: 训练样本集  $D = \{(x, t)\}$

其中  $x = (x_1, \dots, x_d)^t$  为特征向量,  $t$  为 **c** 维目标向量, 用以表示 **x** 的类别:


$t = (1, 0, 0, \dots, 0)^t$       如果  $x \in \omega_1$

$t = (0, 1, 0, \dots, 0)^t$       如果  $x \in \omega_2$

$t = (0, 0, 0, \dots, 1)^t$       如果  $x \in \omega_c$

(4) 神经网络结构:  $d \times n_H \times c$

(5) 激活函数: 可微的非线性函数



(6) 神经网络的训练目标：调整权系数  $\omega$

即所有的  $\omega_{kj}$  及  $\omega_{ji}$ ，使得对于训练集中的每一个训练样本  $(x, t)$ ，网络的输出尽可能满足：

$$z(x) = \begin{pmatrix} z_1(x) \\ \dots \\ z_c(x) \end{pmatrix} = \begin{pmatrix} t_1 \\ \dots \\ t_c \end{pmatrix} = t$$

(7) 优化准则：对于样本集  $D$ ，使下述误差函数取得最小值：

$$J(\omega) = \sum_{x \in D} J_x(\omega)$$
$$J_x(\omega) = \frac{1}{2} \sum_{k=1}^c (t_k - z_k(x))^2$$

实际使用中神经网络对新样本的分类：哪一个输出层神经元的输出值最大,就判该样本属于哪一类.

$$z(x) = \begin{pmatrix} z_1(x) \\ \dots \\ z_c(x) \end{pmatrix} \approx \begin{pmatrix} t_1 \\ \dots \\ t_c \end{pmatrix} = t$$


## 神经网络学习

### 1) 问题的提出

输入一个样本  $(x, t)$ ，计算网络的输出  $z$ ，根据  $z$  与  $t$  的差距调整所有的权系数  $\omega$ ，使  $z$  与  $t$  尽可能接近，即使  $J_x(\omega)$  尽可能小。应该如何调整权系数？

$$J_x(\omega) = \frac{1}{2} \sum_{k=1}^c (t_k - z_k)^2$$

$$J_x(\omega) = \frac{1}{2} \sum_{k=1}^c (t_k - z_k)^2 \quad \text{net}_k = \sum_{j=1}^{n_H} \omega_{kj} y_j + \omega_{k0} \quad \text{net}_j = \sum_{i=1}^d \omega_{ji} x_i + \omega_{j0}$$



$$f(\text{net}) = \frac{1}{1 + e^{-\text{net}}}$$

$$z_k = f(\text{net}_k)$$

$$y_j = f(\text{net}_j)$$



## 2) 权系数的调整方法

### (1) 误差函数:

$$J = J_x(\omega) = \frac{1}{2} \sum_{k=1}^c (t_k - z_k)^2$$

### (2) 计算 $\partial J / \partial \omega_{kj}$ , $\partial J / \partial \omega_{ji}$

### (3) 调整权系数(Gradient Descent Procedure):

$$\omega_{kj} \leftarrow \omega_{kj} - \eta \frac{\partial J}{\partial \omega_{kj}} \qquad \omega_{ji} \leftarrow \omega_{ji} - \eta \frac{\partial J}{\partial \omega_{ji}}$$

### (3) 对输出层权系数的微分

$$\frac{\partial J}{\partial \omega_{kj}} = \frac{\partial J}{\partial net_k} \frac{\partial net_k}{\partial \omega_{kj}}$$

$$\frac{\partial J}{\partial net_k} = \frac{\partial J}{\partial z_k} \frac{\partial z_k}{\partial net_k} = -(t_k - z_k) f'(net_k) \quad \frac{\partial net_k}{\partial \omega_{kj}} = y_j$$

$$\text{令 } \frac{\partial J}{\partial net_k} = \delta_k \quad \text{可得 } \frac{\partial J}{\partial \omega_{kj}} = \delta_k y_j$$

$$J = \frac{1}{2} \sum_{k=1}^c (t_k - z_k)^2$$

$$net_k = \sum_{j=1}^{n_H} \omega_{kj} y_j + \omega_{k0}$$

$$z_k = f(net_k)$$

$$net_j = \sum_{i=1}^d \omega_{ji} x_i + \omega_{j0}$$

$$y_j = f(net_j)$$

#### (4) 对隐层权系数的微分

$$\frac{\partial J}{\partial \omega_{ji}} = \frac{\partial J}{\partial net_j} \frac{\partial net_j}{\partial \omega_{ji}}$$

$$\frac{\partial J}{\partial net_j} = \frac{\partial J}{\partial y_j} \frac{\partial y_j}{\partial net_j} \quad \frac{\partial J}{\partial y_j} = \sum_{k=1}^c \delta_k \omega_{kj} \quad \frac{\partial y_j}{\partial net_j} = f'(net_j)$$

$$\frac{\partial J}{\partial net_j} = f'(net_j) \sum_{k=1}^c \delta_k \omega_{kj} \quad \frac{\partial net_j}{\partial \omega_{ji}} = x_i$$

$$\text{令 } \delta_j = \frac{\partial J}{\partial net_j} \quad \text{可得 } \frac{\partial J}{\partial \omega_{ji}} = \delta_j x_i$$

$$\frac{\partial J}{\partial y_j} = \left\{ \sum_{k=1}^c \frac{\partial J}{\partial z_k} \frac{\partial z_k}{\partial y_j} \right\}$$

$$= - \sum_{k=1}^c (t_k - z_k) \frac{\partial z_k}{\partial y_j}$$

$$= - \sum_{k=1}^c (t_k - z_k) \frac{\partial z_k}{\partial net_k} \frac{\partial net_k}{\partial y_j}$$

$$= - \sum_{k=1}^c (t_k - z_k) f'(net_k) \omega_{kj} = \sum_{k=1}^c \delta_k \omega_{kj}$$

$$J = \frac{1}{2} \sum_{k=1}^c (t_k - z_k)^2$$

$$z_k = f(net_k)$$

$$net_k = \sum_{j=1}^{n_H} \omega_{kj} y_j$$

## (5) 权系数的调整:

$$\omega_{kj} \leftarrow \omega_{kj} - \eta \frac{\partial J}{\partial \omega_{kj}} \quad \frac{\partial J}{\partial \omega_{kj}} = \delta_k y_j \quad \delta_k = -(t_k - z_k) f'(net_k)$$

$$\omega_{ji} \leftarrow \omega_{ji} - \eta \frac{\partial J}{\partial \omega_{ji}} \quad \frac{\partial J}{\partial \omega_{ji}} = \delta_j x_i \quad \delta_j = f'(net_j) \sum_{k=1}^c \delta_k \omega_{kj}$$

# 反向传播算法 (Back Propagation)

- (1) 对于给定的样本集  $D = \{(x, t)\}$ ，初始化网络结构  $d \times n_H \times c$ 。初始化权系数  $\omega$ ，学习速率  $\eta$ ，阈值  $\theta$ ，变量  $k = 1$ 。
- (2) 从D中取出第k个样本  $(x, t)$ ，根据该样本更新权系数  $\omega$ ：  
$$\omega_{kj} \leftarrow \omega_{kj} - \eta \partial J / \partial \omega_{kj} \quad \omega_{ji} \leftarrow \omega_{ji} - \eta \partial J / \partial \omega_{ji}$$
- (3)  $k = k + 1$ ，如果  $k > n$ ，令  $k = 1$ 。转第2步继续进行循环。退出条件：在给定样本集上的平均误差足够小。

$$J = J_x(\omega) = \frac{1}{2} \sum_{k=1}^c (t_k - z_k)^2$$